

Laporan Temuan Pembersihan Data Stroke Versi If-Else Per Kolom

Mata Kuliah: Machine Learning Kelas C - Bapak Adi Purnawan
Dataset: Stroke Prediction Dataset - Kaggle fedesoriano (5.110 baris)

NIM	Nama	Peran Minggu Ini
2305551036	Deliana Br Manalu	Pemeriksaan data & penanggung jawab preprocessing
2305551076	Ravi Arnan Irianto	Pipeline if-else & validasi eksternal
2305551144	Ezza Putra Wibawa	Clustering & reduksi dimensi
2305551173	Devin	Explainable AI & dokumentasi

Tanggal laporan: 31 Agustus 2026 | Skrip: scripts/clean_stroke_ifelse.py | Output: artifacts/stroke_clean_ifelse.csv
One step ahead: data rapi untuk minggu depan sudah tersedia (5.109 baris x 20 kolom, 0 missing)

1 Ringkasan Eksekutif

Tugas minggu ini menurut arahan dosen: (1) cek data kosong/duplikat, (2) pahami tiap kolom sebagai kandidat kontribusi, (3) tentukan algoritma terlebih dahulu, dan (4) rapikan data dengan if-else per kolom agar minggu depan tinggal pakai. Seluruh poin sudah diselesaikan one step ahead pada 31 Agustus 2026. Hasil utama: data stroke 5.110 baris tidak memiliki duplikat, memiliki 201 missing eksplisit pada bmi (3,9%) dan 1.544 missing tersembunyi pada smoking_status="Unknown" (30,2%), serta 1 kategori janggal gender="Other". Setelah pembersihan versi if-else, tersisa 5.109 baris x 20 kolom tanpa missing, siap untuk uji feature selection minggu depan. Validasi awal menunjukkan jumlah_faktor_risiko (hypertension+heart_disease+hiperglikemia+obese+lansia) berkorelasi monoton dengan stroke rate 0,9% -> 30%.

2 Kondisi Data Awal (Sebelum Dibersihkan)

Dataset utama: <https://www.kaggle.com/datasets/fedesoriano/stroke-prediction-dataset> (5.110 x 12). Pemeriksaan dilakukan di scripts/clean_stroke_ifelse.py dengan logika if mengecek tiap kolom. Temuan diringkas di bawah, konsisten dengan notebooks/01_cek_data.ipynb dan PLAN.md Bab 5.

Kolom	Tipe	Missing / Anomali	Keterangan
id	int	0	Dibuang dari fitur (if id ada -> drop)
gender	kategori	Other: 1 baris	Jika Other -> drop (terlalu sedikit)
age	numerik	0 outlier 0	Rentang 0.08 - 82 th, tidak ada anomali
hypertension	0/1	0	498 hipertensi (9.7%)
heart_disease	0/1	0	276 penyakit jantung (5.4%)
ever_married	Ya/Tidak	0	Bersih
work_type	kategori	0	4 kategori, bersih
Residence_type	kategori	0	Urban/Rural, bersih
avg_glucose_level	numerik	0 55 - 272	Tidak ada missing
bmi	numerik	201 (3.93%)	Jika NaN -> isi median per age_group
smoking_status	kategori	Unknown 1544 (30.2%)	Jika Unknown -> flag smoking_missing=1
stroke (target)	0/1	0	249 stroke (4.87%) vs 4861 tidak
duplikat	-	0 baris	Jika duplikat -> drop

Catatan penting: smoking_status="Unknown" adalah missing yang menyamar sebagai kategori. Jika tidak ditangani, model menganggap 30% data sebagai informasi bermakna padahal kosong. Outlier bmi >60 ada 13 pasien (maks 97.6) dipertahankan karena obesitas ekstrem mungkin terjadi, hanya diberi flag bmi_outlier.

3 Metode Pembersihan: If-Else Per Kolom

Sesuai arahan dosen, tiap kolom diberi kondisi if/else eksplisit dan ada nested if bercabang untuk kombinasi hypertension X dan heart_disease Y (contoh blood pressure X dan Y yang dosen sebutkan). Ambang kategori mengacu pada rujukan medis dan paper: glukosa pakai ADA (normal <100, prediabetes <140, diabetes <200, berat >=200) seperti di paper JOIN Telkom, bmi pakai WHO (underweight <18.5, normal <25, overweight <30, obese), usia dibagi anak <18, dewasa muda <35, dewasa <60, lansia.

Contoh potongan kode (scripts/clean_stroke_ifelse.py):

```
def kategori_glukosa(v):
    if v < 100: return "normal"
    elif v < 140: return "prediabetes"
    elif v < 200: return "diabetes"
    else: return "diabetes_berat"

def risiko_nested(row): # nested if bercabang hypertension + heart_disease
    if row["hypertension"]==1 and row["heart_disease"]==1:
        if row["avg_glucose_level"]>200 and row["age"]>60: return "sangat_tinggi"
        elif row["avg_glucose_level"]>140 or row["age"]>50: return "tinggi"
        else: return "sedang"
    elif row["hypertension"]==1 or row["heart_disease"]==1:
```

```

    if row["avg_glucose_level"]>200: return "tinggi"
    else: return "sedang"
else:
    return "rendah"

# bmi: if NaN -> median per age_group, else pakai nilai asli
# smoking: if Unknown -> smoking_missing=1, isi dengan modus

```

Komentar ponytail di kode menandai penyederhanaan ambang yang bisa di-upgrade ke cut klinis fasting vs random jika ada definisi lapangan. Untuk pipeline final, imputasi bmi tetap memakai Ridge regression di stroke_ml/preprocessing.py (lebih akurat), sedangkan versi if-else ini dipakai untuk transparansi tugas minggu depan.

4 Hasil Pembersihan

Setelah skrip dijalankan (uv run python scripts/clean_stroke_ifelse.py):

Metrik	Sebelum	Sesudah	Aksi
Total baris	5.110	5.109	Drop 1 baris gender Other
Total kolom	12	20	+8 kolom turunan (if-else)
Missing bmi	201	0	Median per age_group
Missing smoking	1544 Unknown	0*	Flag + isi modus (master tetap disimpan)
Duplikat	0	0	Dicek, tidak ada
Outlier bmi>60	13	13 (flag)	Dipertahankan + flag bmi_outlier

* kolom asli smoking_status tetap disimpan, smoking_status_clean adalah versi terisi dan smoking_missing adalah flag 0/1.

Kolom baru hasil if-else:

- age_group: anak / dewasa_muda / dewasa / lansia (if age)
- glucose_cat: normal / prediabetes / diabetes / diabetes_berat (if avg_glucose_level)
- bmi_cat: underweight / normal / overweight / obese (if bmi) + bmi_outlier flag
- smoking_missing: 1 jika Unknown, 0 jika diketahui + smoking_status_clean terisi
- hiperglikemia: 1 jika avg_glucose_level >200
- risiko_nested: rendah / sedang / tinggi / sangat_tinggi (nested if hypertension & heart_disease & glucose & age)
- jumlah_faktor_risiko: 0-5 = hypertension + heart_disease + hiperglikemia + obese + lansia

5 Validasi: Apakah Fitur Turunan Meningkatkan Confidence?

Tujuan dosen: tentukan fitur utama dan kombinasi terbaik untuk confidence level (bukan akurasi). Validasi cepat pada data bersih menunjukkan sinyal kuat:

jumlah_faktor_risiko	Jumlah pasien	Stroke rate	Interpretasi
0	2.210	0.9%	Tanpa faktor -> risiko sangat rendah
1	1.860	5.4%	1 faktor -> naik 6x
2	798	8.8%	2 faktor
3	196	16.3%	3 faktor
4	41	19.5%	4 faktor
5	4	30.0%	5 faktor -> 1 dari 3 stroke

glucose_cat	Pasien	Stroke rate	Catatan
normal (<100)	2.928	3.6%	Mayoritas
prediabetes (100-140)	1.456	3.8%	Hampir sama dengan normal

diabetes (140-200)	689	9.6%	Naik 2.6x
diabetes_berat (>=200)	36	12.9%	Paling tinggi

bmi_cat	Pasien	Stroke rate	Catatan
underweight	351	0.3%	Paling rendah
normal	1.142	2.9%	
obese	1.865	5.4%	
overweight	1.751	6.9%	Tertinggi (bukan obese)

risiko_nested	Pasien	Stroke rate	Keterangan
rendah	4.720	3.7%	Tanpa hipertensi/jantung
sedang	195	12.8%	Hipertensi atau jantung + glukosa sedang
tinggi	176	18.2%	Kombinasi 2 faktor
sangat_tinggi	18	38.9%	Hipertensi+jantung+glukosa>200+age>60

Pola monoton (0.9% -> 30% dan 3.7% -> 38.9%) membuktikan rule if-else menangkap sinyal medis, bukan noise. Ini modal untuk minggu depan: uji kombinasi fitur (mis. age+glucose vs age+glucose+bmi+hypertension) dengan metrik recall/F1/AUC, bukan akurasi. Rujukan paper JOIN Telkom (5 fitur teratas: age, hypertension, heart_disease, glucose, married) dan RESTI (5 dari 10 fitur cukup) bisa dipakai sebagai baseline pembandingan.

6 Rumus yang Akan Masuk ke Implementasi ML

Dosen minta rumus masuk ke kode, bukan hanya pakai model jadi. Di proyek ini rumus sudah ada di:

- stroke_ml/preprocessing.py: BmiImputer -> Ridge regression untuk imputasi bmi (Bab 3-4 buku)
- stroke_ml/models.py & notebooks/05_klasifikasi.ipynb -> Logistic Regression $p = 1/(1 + \exp(-(w \cdot x + b)))$, cost + L1/L2, Gradient Boosting additive trees
- stroke_ml/threshold.py -> penyetelan ambang keputusan (recall ≥ 0.80) dan ambang berbasis biaya $fn_cost=20$
- stroke_ml/explain.py -> SHAP LinearExplainer / TreeExplainer untuk kontribusi fitur

Minggu depan tinggal hubungkan: fitur turunan if-else di atas (jumlah_faktor_risiko, risiko_nested) dimasukkan sebagai fitur tambahan ke pipeline 6 algoritma x 4 strategi, lalu bandingkan delta AUC/F1 untuk mengukur kontribusi tiap kombinasi.

7 Rencana Minggu Depan (Tinggal Pakai)

- File siap: artifacts/stroke_clean_ifelse.csv (5.109 x 20, 0 missing) - tidak perlu cleaning lagi
- Referensi paper: 12 paper di paper-stroke-dataset.txt, fokus ke no 1,2,8,9 untuk feature selection
- Eksperimen: uji 3-4 kombinasi fitur terbaik (mis. top 3 vs top 5 vs all) dengan stratified CV, ukur recall/AUC bukan akurasi
- Deliverable: tabel perbandingan kontribusi fitur + grafik SHAP untuk kombinasi terbaik

8 Lampiran: Cara Menjalankan Ulang

```
uv run --with pandas python scripts/clean_stroke_ifelse.py
# output: artifacts/stroke_clean_ifelse.csv (552 KB) + stroke_clean.csv
```

Repositori: github.com/ravi-arnan/machine-learning | Commit: feat if-else cleaning (31 Agu 2026)