

Laporan Temuan FULL SCOPE

Pembersihan Data Stroke

Semua Kolom Diuji

Mata Kuliah: Machine Learning Kelas C - Bapak Adi Purnawan
Dataset: Kaggle fedesoriano 5.110 baris -> bersih 5.109 x 20 (0 missing)

NIM	Nama	Peran
2305551036	Deliana Br Manalu	Preprocessing & if-else per kolom
2305551076	Ravi Arnan Irianto	Pipeline & full scope check
2305551144	Ezza Putra Wibawa	Clustering & PCA
2305551173	Devin	XAI & dokumentasi

31 Agustus 2026 | *scripts/clean_stroke_ifelse.py* + *full scope check* | *artifacts/stroke_clean_ifelse.csv*
Versi ini: SEMUA kolom diuji (full scope). Versi ringkas tetap ada di *laporan_temuan.pdf* (4 hal)

Perbedaan versi: Ringkas = 4 tabel validasi (jumlah_faktor_risiko, glucose_cat, bmi_cat, risiko_nested). Full = 13 tabel kategorikal + korelasi numerik + ranking kontribusi semua fitur.

1 Ringkasan Eksekutif - Full Scope

Tugas minggu ini one step ahead sudah selesai: duplikat 0, bmi missing 201 (3.9%) diisi median per age_group, smoking Unknown 1544 (30.2%) di-flag, gender Other 1 baris di-drop. Hasil bersih 5.109 x 20 tanpa missing. Uji awal di laporan ringkas hanya 4 tabel. Di versi full ini SEMUA kolom diuji stroke rate per kategori + korelasi numerik. Kesimpulan tetap: age (korelasi 0.245) paling kuat, diikuti jumlah_faktor_risiko 0.213, heart_disease 0.134, glucose 0.132, hypertension 0.127, bmi 0.040 paling lemah. Gender dan Residence_type hampir tidak membedakan risiko.

2 Kondisi Awal & Aturan If-Else Per Kolom

Tiap kolom punya if/else eksplisit di scripts/clean_stroke_ifelse.py: kategori_glukosa (ADA), kategori_bmi (WHO), kategori_usia, risiko_nested (nested if hypertension X dan heart_disease Y). Contoh: if hypertension==1 and heart_disease==1 and glucose>200 and age>60 -> sangat_tinggi (38.9% stroke).

Kolom	Missing/Anomali	Aturan If-Else
gender	Other 1	if Other -> drop
age	0	if <18 anak, <35 muda, <60 dewasa, else lansia
hypertension	0	if bukan 0/1 -> paksa 0/1
heart_disease	0	if bukan 0/1 -> paksa 0/1
ever_married	0	bersih, cek Unknown
work_type	0	4 kategori
Residence_type	0	Urban/Rural
avg_glucose	0	if <100 normal, <140 pre, <200 diabetes, else berat
bmi	201 NaN	if NaN -> median per age_group else nilai asli
smoking_status	Unknown 1544	if Unknown -> flag 1 + isi modus
stroke	0	target 249/4861 (4.87%)
duplikat	0	if duplikat -> drop

3 Hasil Full Scope - Semua Kategorikal

Stroke rate overall 4.87% (249/5109). Di bawah ini rate per kategori, diurut dari yang paling membedakan:

3.1 Demografi & Sosial

age_group	N	Rate	Arti
lansia (>=60)	1376	13.15%	Paling tinggi
dewasa (35-59)	1889	3.44%	
anak (<18)	856	0.23%	Paling rendah
dewasa_muda (18-34)	988	0.10%	Paling rendah

gender	N	Rate	Delta
Female	2994	4.71%	-
Male	2115	5.11%	+0.4% (tidak signifikan)

ever_married	N	Rate	Catatan
Yes	3353	6.56%	Confounded usia
No	1756	1.65%	Mayoritas anak/muda

work_type	N	Rate	Catatan
-----------	---	------	---------

Self-employed	819	7.94%	Tertinggi
Private	2924	5.10%	
Govt_job	657	5.02%	
children	687	0.29%	Anak
Never_worked	22	0.00%	Sampel kecil

Residence_type	N	Rate	Delta
Urban	2596	5.20%	
Rural	2513	4.54%	+0.66% ns

3.2 Riwayat Penyakit & Klinis

hypertension	N	Rate	Lift
1 Ya	498	13.25%	3.3x vs tanpa
0 Tidak	4611	3.97%	

heart_disease	N	Rate	Lift
1 Ya	276	17.03%	4.0x vs tanpa
0 Tidak	4833	4.18%	

glucose_cat (ADA)	N	Rate	Lift
diabetes_berat >=200	434	12.90%	3.6x vs normal
diabetes 140-199	386	9.59%	2.6x
prediabetes 100-139	1158	3.80%	~normal
normal <100	3131	3.58%	baseline

hiperglikemia (>200)	N	Rate	Sama dengan diabetes_berat
1 Ya	434	12.90%	
0 Tidak	4675	4.13%	

bmi_cat (WHO)	N	Rate	Catatan
overweight 25-29.9	1527	6.94%	Tertinggi
obese >=30	1983	5.35%	
normal 18.5-24.9	1262	2.85%	Rendah
underweight <18.5	337	0.30%	Paling rendah

bmi_outlier (>60)	N	Rate	Catatan
1 Ya (13 pasien)	13	0.00%	Semua tidak stroke - outlier tidak berisiko
0 Tidak	5096	4.89%	

3.3 Kebiasaan Merokok

smoking_status (asli)	N	Rate	Catatan
formerly smoked	884	7.92%	Tertinggi
smokes	789	5.32%	
never smoked	1892	4.76%	

Unknown	1544	3.04%	Paling rendah (lebih muda)
---------	------	-------	----------------------------

smoking_status_clean	N	Rate	Setelah Unknown diisi modus never
formerly smoked	884	7.92%	
smokes	789	5.32%	
never smoked	3436	3.99%	Gabungan never+Unknown

smoking_missing flag	N	Rate	Artinya
0 diketahui	3565	5.67%	
1 Unknown	1544	3.04%	Kelompok Unknown lebih muda

3.4 Fitur Turunan Nested If

risiko_nested	N	Rate	Definisi
sangat_tinggi	18	27.78%	HT+HD+glucose>200+age>60
tinggi	176	19.32%	Kombinasi 2 faktor
sedang	195	15.38%	HT/HD + glucose sedang
rendah	4720	3.81%	Tanpa HT/HD

jumlah_faktor_risiko (0-5)	N	Rate	Isi: HT+HD+hiper+obese+lansia
0	2215	0.90%	Tanpa faktor
1	1715	5.36%	
2	787	8.77%	
3	300	16.33%	
4	82	19.51%	
5	10	30.00%	1 dari 3 stroke

Pola monoton 0.9% -> 30% membuktikan kombinasi if-else menangkap sinyal, siap diuji sebagai fitur untuk meningkatkan confidence (AUC/F1).

4 Korelasi Numerik vs Stroke (Full Scope)

Korelasi Pearson terhadap target stroke, diurutkan:

Peringkat	Fitur	Korelasi	Kekuatan
1	age	0.245	Kuat - lansia dominan
2	jumlah_faktor_risiko	0.213	Kuat - hitungan if-else
3	heart_disease	0.134	Sedang
4	avg_glucose_level	0.132	Sedang
5	hypertension	0.127	Sedang
6	bmi	0.040	Lemah

bmi korelasi hanya 0.04 sehingga kontribusi tunggalnya kecil; tapi kombinasi overweight+glucose+age tetap penting (lihat bmi_cat 6.9% vs 0.3%).

5 Ranking Kontribusi Semua Fitur (Untuk Uji Minggu Depan)

Berdasarkan lift stroke rate dan korelasi, urutan untuk feature selection minggu depan:

- Tier 1 (wajib): age / age_group, heart_disease, hypertension, avg_glucose_level / glucose_cat / hiperglikemia

- Tier 2 (pendukung): jumlah_faktor_risiko, risiko_nested, bmi_cat, formerly smoked
- Tier 3 (lemah): gender, Residence_type, bmi numerik mentah, bmi_outlier
- Rekomendasi kombinasi uji: (a) Tier1 saja, (b) Tier1+Tier2, (c) semua fitur. Baseline pembandingan: 5 fitur JOIN Telkom (age, HT, HD, glucose, married) dan 5 fitur RESTI.

Metrik minggu depan: recall (≥ 0.80 target), F1, ROC-AUC, bukan akurasi. SMOTE hanya di train fold.

6 File & Cara Pakai

```
uv run --with pandas python scripts/clean_stroke_ifelse.py
# -> artifacts/stroke_clean_ifelse.csv (5109 x 20, 0 missing, siap)
# versi ringkas: laporan_temuan.pdf (4 hal)
# versi lengkap: laporan_temuan_full.pdf (ini)
```

Repo: github.com/ravi-arnan/machine-learning | Commit full scope menyusul